SAÉ 4.EMS.01

Présenté par ;

Ahmed TERIR
Zakaria CHAREF

Encadré par :

Mme Herrmann

MODÉLISATION STATISTIQUE

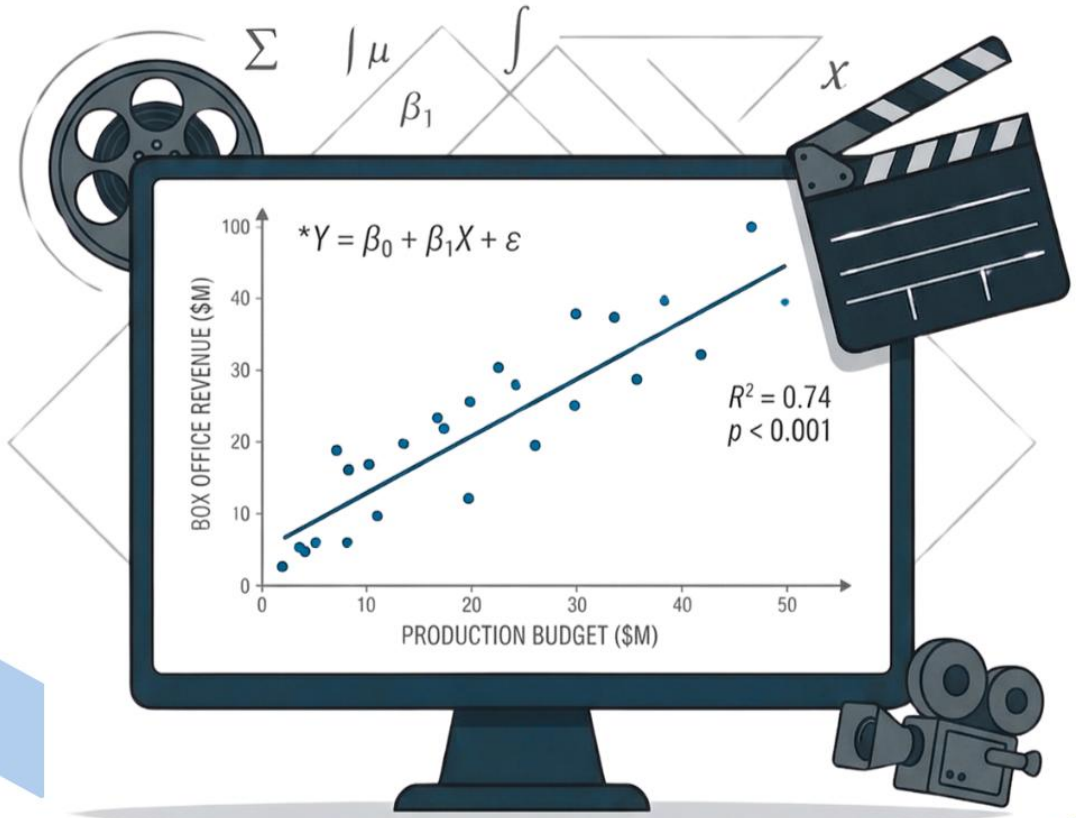

SAE 4.EMS.01

Présentation de la Région

PROVENCE-ALPES-CÔTE D'AZUR

Infrastructures cinématographiques et fréquentation — 2022

1. Présentation générale de la région PACA

1.1 Géographie et organisation administrative

La région Provence-Alpes-Côte d'Azur (PACA), également appelée « Région Sud », est située dans le sud-est de la France métropolitaine. Elle est bordée par la mer Méditerranée au sud, l'Italie à l'est, et partage ses frontières avec les régions Occitanie et Auvergne-Rhône-Alpes.

Elle est composée de 6 départements :

- Bouches-du-Rhône (13) — Chef-lieu : Marseille
- Var (83) — Chef-lieu : Toulon
- Alpes-Maritimes (06) — Chef-lieu : Nice
- Vaucluse (84) — Chef-lieu : Avignon
- Alpes-de-Haute-Provence (04) — Chef-lieu : Digne-les-Bains
- Hautes-Alpes (05) — Chef-lieu : Gap

Ses principales villes sont Marseille (2e ville de France), Nice, Toulon, Aix-en-Provence, Cannes et Avignon.

1.2 Démographie

Au 1er janvier 2022, 5 170 312 personnes vivent en Provence-Alpes-Côte d'Azur, soit 7,9 % de la population de France métropolitaine, ce qui en fait la 7e région de France par sa population. Entre 2016 et 2022, la population régionale croît en moyenne de 0,5 % chaque année, un rythme légèrement supérieur au niveau national (+0,4 %). La densité de population est de 166,2 habitants/km², soit deux fois supérieure à la moyenne nationale (107,6 hab./km²).

Population (2022)	Croissance annuelle	Densité (hab./km²)
5 170 312 hab.	**+0,5 % / an**	**166,2 hab./km²**

1.3 Économie

En 2022, l'activité économique régionale dépasse son niveau d'avant-crise (Covid-19). L'emploi franchit le cap des deux millions de salariés, et le taux de chômage recule sur l'ensemble du territoire. Le PIB régional s'établit à environ 122 milliards d'euros en 2022.

Principaux secteurs économiques :

- Tourisme : la PACA est la 1ère destination touristique française avec des sites emblématiques (Côte d'Azur, Marseille, Aix-en-Provence, Avignon…)
- Services et économie de la connaissance (industries numériques, recherche, enseignement supérieur)
- Artisanat : 131 300 établissements artisanaux de 0 à 10 salariés générant 7 milliards d'euros de valeur ajoutée
- Agriculture méditerranéale diversifiée : viticulture (Côtes-de-Provence), maraîchage, oléiculture, floriculture
- Défense et industrie navale (base navale de Toulon, 1er port militaire français)

2. Infrastructures cinématographiques en PACA (2022)

2.1 Contexte national

Pour situer la PACA dans son contexte, au niveau national en 2022, le CNC a recensé 2 061 cinémas actifs (+32 par rapport à 2021) pour 6 298 écrans au total (+107). La fréquentation nationale atteint 152,0 millions d'entrées, soit +59,2 % par rapport à 2021, dans un contexte de reprise post-Covid.

2.2 Position de PACA dans le panorama national

La PACA se distingue comme l'une des régions les plus dynamiques du cinéma français en 2022. Deux indicateurs illustrent particulièrement bien cette position :

Indicateur	PACA en 2022
Indice de fréquentation (entrées/habitant)	**2,58 — 2e rang national (après Île-de-France : 3,08)**
Hausse des entrées vs 2021	**+70,8 % — 2e plus forte progression nationale**
Prix de la place de cinéma	Parmi les plus élevés de France (grandes agglomérations)

La forte hausse des entrées en PACA (+70,8 %) est due en partie à l'expansion du parc de salles et au rebond post-Covid, en particulier dans les grandes villes (Marseille, Nice, Toulon, Aix-en-Provence).

2.3 Parc cinématographique en PACA

Le parc cinématographique de la région PACA comprend des établissements de toutes catégories, des mono-écrans de proximité aux grands multiplexes. Les données précises issues du fichier CNC (etablissements-cinematographiques.csv) permettent de détailler :

- Le nombre total d'établissements actifs au 31/12/2022
- Le nombre d'écrans et de fauteuils par établissement
- La répartition géographique par département
- La classification Art & Essai
- Le nombre d'entrées réalisées en 2022

2.4 Fréquentation cinématographique

Le cinéma en PACA bénéficie d'une fréquentation structurellement forte, liée à la densité urbaine (Marseille, Nice, Toulon, Aix-en-Provence) et à la présence de nombreux événements culturels (Festival de Cannes, Fête du Cinéma, etc.).

Indicateur de fréquentation	Valeur 2022
Entrées totales PACA (2022)	À compléter (source CSV/CNC)
Indice de fréquentation	**2,58 entrées par habitant**
Évolution vs 2021	**+70,8 %**
Rang national (fréquentation/hab.)	**2e (après Île-de-France)**

3. La filière cinéma et audiovisuelle en PACA

3.1 Aides publiques et financement

La filière cinéma en PACA bénéficie d'un système de financement conjoint entre le CNC (Centre National du Cinéma et de l'image animée) et la Région, dans le cadre d'une convention CNC/Région. Ce dispositif, appelé « 1 pour 2 », prévoit qu'1 euro apporté par le CNC est complété par 2 euros de la collectivité régionale.

Les aides couvrent plusieurs volets :

- Aide à l'écriture et au développement de projets
- Soutien à la production de courts et longs métrages
- Aide à l'exploitation des salles (programmation difficile, petite et moyenne exploitation)
- Soutien aux tournages en région (accueil de productions)
- Aide aux salles Art & Essai

3.2 Emplois dans le secteur

La filière cinéma et audiovisuelle est un employeur significatif en PACA. La région concentre un nombre important d'entreprises de production, dont une majorité est localisée dans les Bouches-du-Rhône (Marseille).

Caractéristique	Donnée PACA
Part des établissements de production (secteur cinéma/audiovisuel)	**> 51,8 % des établissements du secteur**
Structure des entreprises	Majorité de TPE : 68 % sans salarié, 15 % avec 1-2 salariés
Emplois cinéma (national — pour contexte)	206 000 emplois en France (CNC, 2022)

3.3 Attractivité pour les tournages

La région PACA constitue un territoire particulièrement attractif pour les tournages cinématographiques, grâce à plusieurs atouts naturels et logistiques :

- Diversité et richesse des décors naturels : mer, montagne, garrigue, centre-villes historiques
- Ensoleillement exceptionnel (300 jours de soleil par an en moyenne)
- Présence de compétences techniques reconnues (techniciens, équipes locales)
- Deux grandes agglomérations offrant une palette variée de décors (Marseille, Nice)
- Soutien institutionnel via le fonds d'aide régional et les conventions CNC

La région reçoit ainsi chaque année plusieurs dizaines de longs métrages en tournage, dont plus de 60 % se font sans aucune aide financière publique, ce qui témoigne de son attractivité intrinsèque.

4. Synthèse

La région PACA représente un territoire cinématographique d'exception en France. Avec le 2e indice de fréquentation national (2,58 entrées par habitant en 2022), une croissance record des entrées post-Covid (+70,8 %) et une filière de production audiovisuelle bien implantée, elle constitue un terrain d'étude idéal pour la modélisation statistique des entrées cinématographiques.

Force	Indicateur clé	Valeur 2022
Fréquentation	Indice (entrées/hab.)	**2,58 — 2e national**
Rebond post-Covid	Hausse des entrées	**+70,8 %**
Population	Nombre d'habitants	**5 170 312 hab.**
Cinéma national	Entrées totales France	**152 millions**

[Reporting Power BI réalisé en première année : Région PACA]

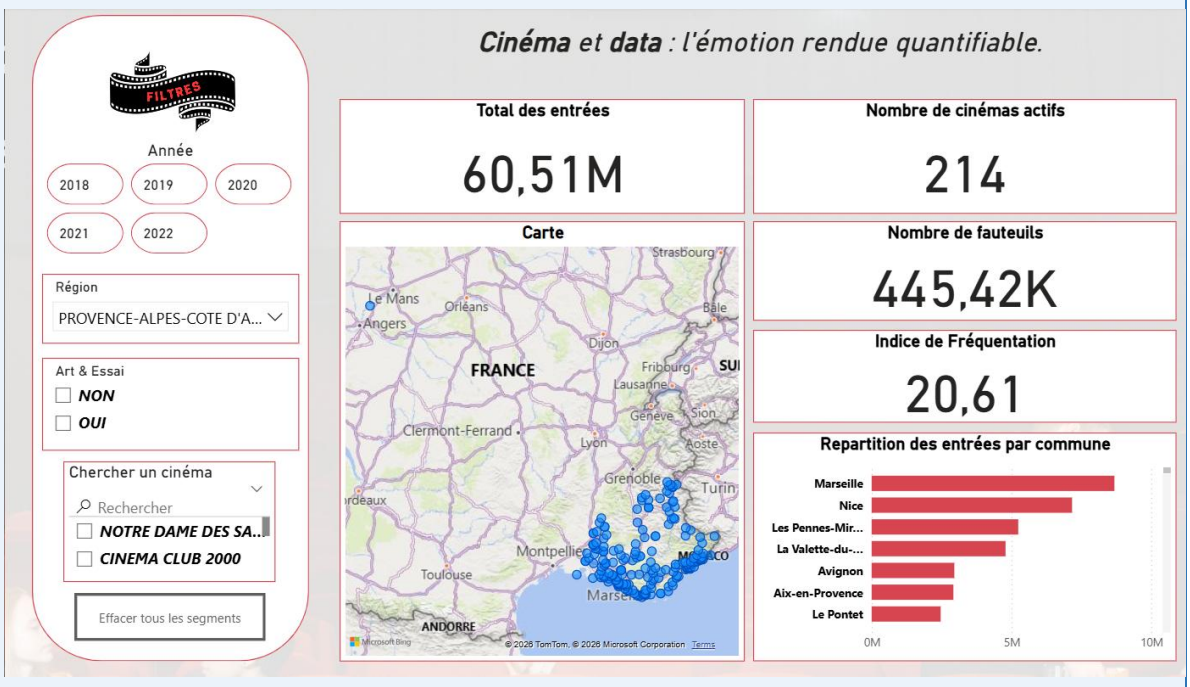

5. Régression linéaire simple

1. Entrées en 2022 en fonction du nombre de fauteuils

- **L'équation estimée de la droite des moindres carrés. Déterminer le coefficient de détermination.**

$$\hat{y} = -35\,271 + 218,28 \times fauteuils$$

R carré	0.8479

L'équation estimée de la droite des moindres carrées s'ajuste très bien au données la variation des entrées en 2022 est expliquée a 84,79% par l'équation estimé entre les entrées et le nombre de fauteuils.

- **La liaison globale entre ces deux variables est-elle significative ?**
- **Test de Fisher :**

$$H_0 : CMexp = CMres$$
$$H_1 : CMexp \neq CMres$$

[Tableau d'ANOVA]

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	1	3.372172E12	3.372172E12	1098.13	<.0001
Erreur	197	6.04952E11	3070822508		
Total sommes corrigées	198	3.977124E12			

La probabilité critique est inférieure à 0.05 donc on rejette H0.

La liaison entre les fauteuils et les entrées en 2022 est significative

- **Déterminer les intervalles de confiance pour la pente de la droite ainsi que pour l'ordonnée à l'origine.**

[Intervalles de confiance]

Paramètres estimés							
Variable	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > |t|	Intervalle de confiance à95%	
Intercept	1	-35271	4996.78242	-7.06	<.0001	-45125	-25417
fauteuils	1	218.27746	6.58690	33.14	<.0001	205.28756	231.26736

a ∈ [-45125 -25417]

b ∈ [205.28756, 231.26736]

- **Les résidus ont-ils une espérance nulle ?**

$$\boldsymbol{H_0} : \boldsymbol{E}(\varepsilon x) = \mathbf{0}$$
$$\boldsymbol{H_1} : \boldsymbol{E}(\varepsilon x) \neq \mathbf{0}$$

[Probabilité Tests de tendance centrale]

Tests de tendance centrale : Mu0=0				
Test	Statistique		p-value	
t de Student	t	0	Pr > |t|	1.0000
Signe	M	10.5	Pr >= |M|	0.1561
Rang signé	S	841	Pr >= |S|	0.3024

La probabilité critique est supérieure au seuil 0.05 donc on accepte $\boldsymbol{H_0}$,les résidus ont bien une espérance nulle

- **Les résidus suivent-ils une loi normale ?**

Test de Normalité :

$$H_0 : \textit{Les résidus suivent une loi Normale}$$
$$H_1 : \textit{Les résidus ne suivent pas une loi Normale}$$

[Tests de Normalité : Stat Kolmogorov car n<50]

Tests de normalité				
Test	Statistique		p-value	
Shapiro-Wilk	W	0.748309	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.18789	Pr > D	<0.0100
Cramer-von Mises	W-Sq	2.143529	Pr > W-Sq	<0.0050
Anderson-Darling	A-Sq	11.84792	Pr > A-Sq	<0.0050

La probabilité est inférieure à 0.05 donc on refuse H0, du fait les résidus ne suivent pas une loi Normale.

- **Sont-ils indépendants ?**

Test de non-corrélation :

$$H_0 : \textit{Les résidus ne sont pas corrélés}$$
$$H_1 : \textit{Les résidus sont corrélés}$$

[Durbin-Watson]

Durbin-Watson D	2.083
Pr < DW	0.7211
Pr > DW	0.2789
Nombre d'observations	199
Autocorrélation de 1er ordre	-0.054

La statistique est comprise entre 1,5 et 2,5 donc on peut accepter H0.

- **Les résidus ont-ils une variance commune ?**

[Nuage de points des résidus]

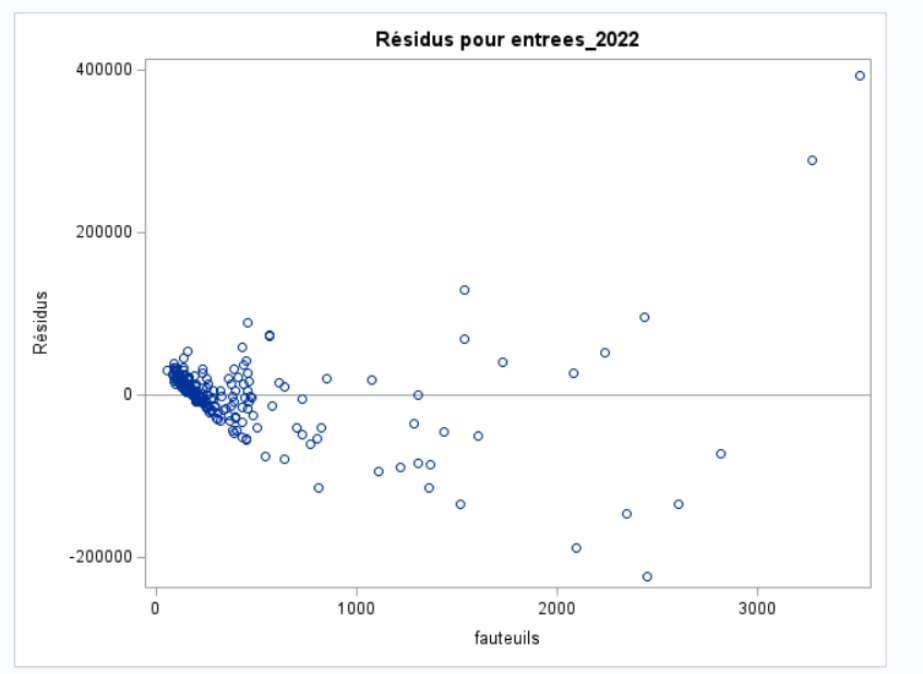

Forme en entonnoir le modèle nécessite changement de variable

- **Le modèle linéaire est-il approprié ?**

  Les observations 15 ,68,82,65,95,104,131,155,190,199 sont mal reconstitués par le modelé sont mal reconstitués par le modèle (>2) en valeur absolue (Rstudent)

  Les observations 1,15,22,82,95,127,131,155,166,168,183,190 ont une forte influence sur la construction de la droite des moindres des carrées (>4/n = 0.02) Pour les levier (Diag de H)

  Sur ce nouveau modèle dans lequel nous avons supprimé les valeurs avec une forte influence et mal reconstitués nous réeffectuons les différents tests

$$\textbf{R carré} \quad 0.8258$$

- **La liaison globale entre ces deux variables est-elle significative ?**

$$H_0 : CMexp = CMres$$
$$H_1 : CMexp \neq CMres$$

Régression linéaire simple avec valeurs supprimées : entrees_2022 = f(fauteuils)

La procédure REG
Modèle : MODEL1
Variable dépendante : entrees_2022

Nb d'observations lues	183
Nb d'obs. utilisées	183

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	1	5.297482E11	5.297482E11	858.33	<.0001
Erreur	181	1.1171E11	617182349		
Total sommes corrigées	182	6.414582E11			

La probabilité critique est inférieure à 0.05 donc on rejette H0

- **Déterminer les intervalles de confiance pour la pente de la droite ainsi que pour l'ordonnée à l'origine.**

Paramètres estimés							
Variable	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > |t|	Intervalle de confiance à95%	
Intercept	1	-18710	2633.78268	-7.10	<.0001	-23907	-13513
fauteuils	1	168.16857	5.74007	29.30	<.0001	156.84252	179.49462

- **Les résidus ont-ils une espérance nulle ?**

$$\boldsymbol{H_0} : \boldsymbol{E}(\varepsilon x) = \mathbf{0}$$
$$\boldsymbol{H_1} : \boldsymbol{E}(\varepsilon x) \neq \mathbf{0}$$

Tests de tendance centrale : Mu0=0				
Test	Statistique		p-value	
t de Student	t	0.036795	Pr > |t|	0.9707
Signe	M	10.5	Pr >= |M|	0.1391
Rang signé	S	913	Pr >= |S|	0.2041

La probabilité critique est supérieure au seuil 0.05 donc on accepte H0, les résidus ont bien une espérance nulle

- **Les résidus suivent-ils une loi normale ?**

Test de Normalité :

$$H_0 : \textit{Les résidus suivent une loi Normale}$$
$$H_1 : \textit{Les résidus ne suivent pas une loi Normale}$$

Tests de normalité				
Test	Statistique		p-value	
Shapiro-Wilk	W	0.94935	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.102455	Pr > D	<0.0100
Cramer-von Mises	W-Sq	0.484231	Pr > W-Sq	<0.0050
Anderson-Darling	A-Sq	3.000634	Pr > A-Sq	<0.0050

La probabilité est inférieure à 0.05 donc on refuse H0.

- **Sont-ils indépendants ?**

Test de non-corrélation :

$$H_0 : \textit{Les résidus ne sont pas corrélés}$$
$$H_1 : \textit{Les résidus sont corrélés}$$

Régression linéaire simple avec valeurs supprimées : entrees_2022 = f(fauteuils)

La procédure REG
Modèle : MODEL1
Variable dépendante : entrees_2022

Durbin-Watson D	2.186
Pr < DW	0.8982
Pr > DW	0.1018
Nombre d'observations	183
Autocorrélation de 1er ordre	-0.103

La statistique DW doit être comprise entre 1,5 et 2,5 donc on peut accepter H0.

- **Les résidus ont-ils une variance commune ?**

-

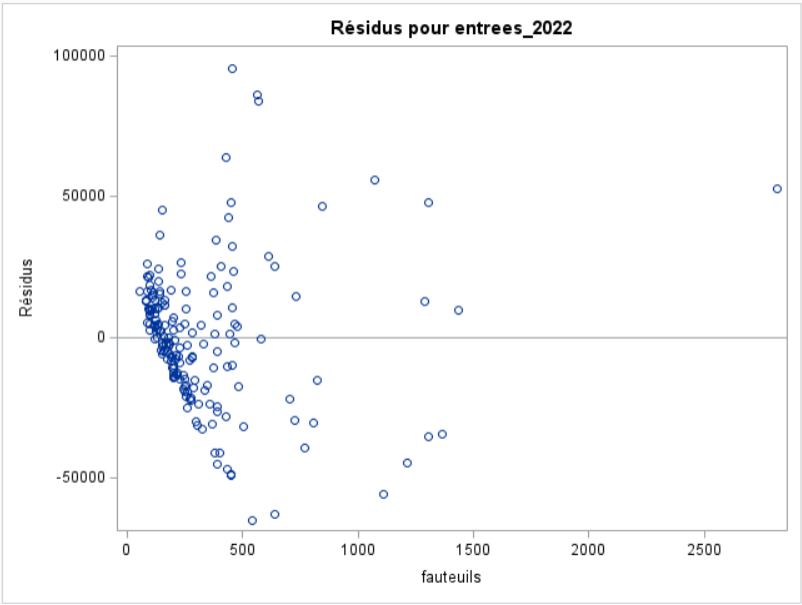

Il y a une forme particulière donc nous testons le changement de variable avec le modèle racine.

Changement de variable : $entree_{2022} \rightarrow \sqrt{entree_2022}$

- **La liaison globale entre ces deux variables est-elle significative ?**

$$\boldsymbol{H_0 : CMexp = CMres}$$
$$\boldsymbol{H_1 : CMexp \neq CMres}$$

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	1	5148827	5148827	1106.51	<.0001
Erreur	197	916684	4653.21790		
Total sommes corrigées	198	6065511			

La probabilité critique est inférieure à 0.05 donc on rejette H0

- **Déterminer les intervalles de confiance pour la pente de la droite ainsi que pour l'ordonnée à l'origine.**

Paramètres estimés							
Variable	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > |t|	Intervalle de confiance à95%	
Intercept	1	64.81753	6.15092	10.54	<.0001	52.68743	76.94762
fauteuils	1	0.26972	0.00811	33.26	<.0001	0.25373	0.28571

- **Les résidus ont-ils une espérance nulle ?**

$$H_0 : E(\varepsilon x) = 0$$
$$H_1 : E(\varepsilon x) \neq 0$$

Tests de tendance centrale : Mu0=0				
Test	Statistique		p-value	
t de Student	t	0	Pr > |t|	1.0000
Signe	M	-3.5	Pr >= |M|	0.6707
Rang signé	S	-289	Pr >= |S|	0.7233

La probabilité critique est supérieure au seuil 0.05 donc on accepte H0, les résidus ont bien une espérance nulle

- **Les résidus suivent-ils une loi normale ?**

Test de Normalité :

$$H_0 : \textit{Les résidus suivent une loi Normale}$$
$$H_1 : \textit{Les résidus ne suivent pas une loi Normale}$$

Tests de normalité				
Test	Statistique		p-value	
Shapiro-Wilk	W	0.992311	Pr < W	0.3800
Kolmogorov-Smirnov	D	0.038421	Pr > D	>0.1500
Cramer-von Mises	W-Sq	0.054147	Pr > W-Sq	>0.2500
Anderson-Darling	A-Sq	0.375736	Pr > A-Sq	>0.2500

La probabilité est supérieure à 0.05 donc on accepte H0.

- **Sont-ils indépendants ?**

Test de non-corrélation :

$$H_0 : \textit{Les résidus ne sont pas corrélés}$$
$$H_1 : \textit{Les résidus sont corrélés}$$

La procédure REG
Modèle : MODEL1
Variable dépendante : racine_entrees

Durbin-Watson D	2.091
Pr < DW	0.7413
Pr > DW	0.2587
Nombre d'observations	199
Autocorrélation de 1er ordre	-0.051

- **Les résidus ont-ils une variance commune ?**
-

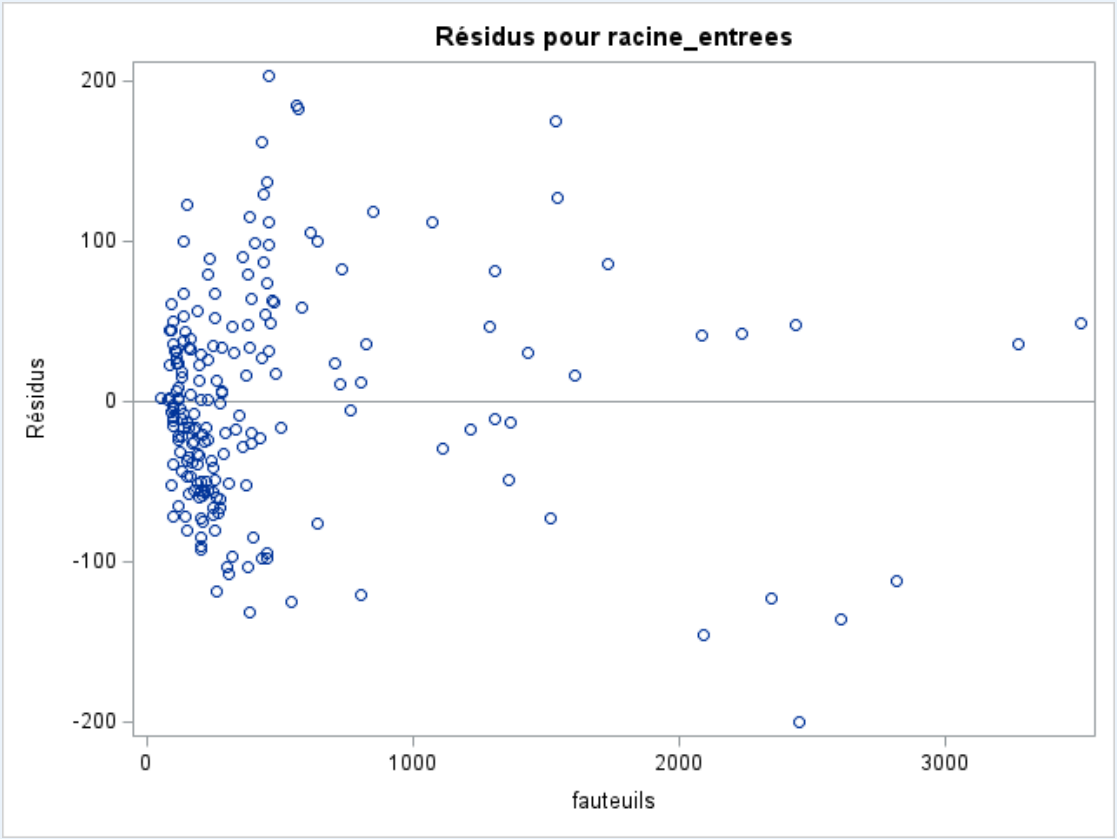

Il n'y a pas de forme particulière donc le modèle linéaire avec la racine est adapté.

- **Déterminer les points ayant une forte influence sur le calcul des paramètres du modèle.**
  Le seuil est donné par $2 \times \frac{2}{n} = 2 \times \frac{2}{199} = 0.0201$ car nous sommes sur un modele a une variable quantitative indépendante.

  Les observations 1,15,22,68,131,132,182 ont une forte influence sur la construction de la droite des moindres des carrées

- **Déterminer les points mal reconstitués par le modèle.**

Les observations 38,55,68,95,104,190,191 sont mal reconstitués par le modèle (Seuil Rstudent > |2|)

6. Régression linéaire multiple (deux variables indépendante)

Forme du modèle : $\hat{y} = \beta_0 + \beta_1 x1 + \beta_2 x2$

Premier modèle choisi : $\mathbf{log}(\boldsymbol{entree_{2022}}) = \boldsymbol{\beta_0} + \boldsymbol{\beta_1} \times \boldsymbol{fauteuils} + \boldsymbol{\beta_2} \times \boldsymbol{séances}$

Equation obtenue : $\mathbf{log}(\boldsymbol{entree_{2022}}) = \mathbf{9,17740} - \mathbf{0,00131} \times \boldsymbol{fauteuils} + \mathbf{0,00034774} \times \boldsymbol{séances}$

Performance du modèle : **R2 = 0,6929**

Intervalles de confiance (à 95 %) :

- Ordonnée a l'origine : [9,01440 ; 9,34039]
- Pente (fauteuils) : [-0,00198 ; -0,00065]

Pente (séances) : [0,00028 ; 0,00041]

- **La liaison globale entre ces deux variables est-elle significative ?**

$$\boldsymbol{H_0 : CMexp = CMres}$$
$$\boldsymbol{H_1 : CMexp \neq CMres}$$

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	2	345.45278	172.72639	221.08	<.0001
Erreur	196	153.13522	0.78130		
Total sommes corrigées	198	498.58800			

La probabilité critique est inférieure à 0.05 donc on rejette H0

- **Les résidus ont-ils une espérance nulle ?**

$$\boldsymbol{H_0} : \boldsymbol{E}(\varepsilon x) = \mathbf{0}$$
$$\boldsymbol{H_1} : \boldsymbol{E}(\varepsilon x) \neq \mathbf{0}$$

Tests de tendance centrale : Mu0=0				
Test	Statistique		p-value	
t de Student	t	0	Pr > |t|	1.0000
Signe	M	-3.5	Pr >= |M|	0.6707
Rang signé	S	-289	Pr >= |S|	0.7233

La probabilité critique est supérieure au seuil 0.05 donc on accepte H0, les résidus ont bien une espérance nulle

- **Les résidus suivent-ils une loi normale ?**

Test de Normalité :

$$\boldsymbol{H_0} : \boldsymbol{Les\ résidus\ suivent\ une\ loi\ Normale}$$
$$\boldsymbol{H_1} : \boldsymbol{Les\ résidus\ ne\ suivent\ pas\ une\ loi\ Normale}$$

Tests de normalité				
Test	Statistique		p-value	
Shapiro-Wilk	W	0.95718	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.059412	Pr > D	0.0855
Cramer-von Mises	W-Sq	0.225288	Pr > W-Sq	<0.0050
Anderson-Darling	A-Sq	1.62215	Pr > A-Sq	<0.0050

La probabilité est supérieure à 0.05 donc on accepte H0.

- **Sont-ils indépendants ?**

Test de non-corrélation :

$$H_0 : \textit{Les résidus ne sont pas corrélés}$$
$$H_1 : \textit{Les résidus sont corrélés}$$

Durbin-Watson D	1.978
Pr < DW	0.4390
Pr > DW	0.5610
Nombre d'observations	199
Autocorrélation de 1er ordre	0.009

La statistique DW doit être comprise entre 1,5 et 2,5 donc on peut accepter H0.

- **Les résidus ont-ils une variance commune ?**

-

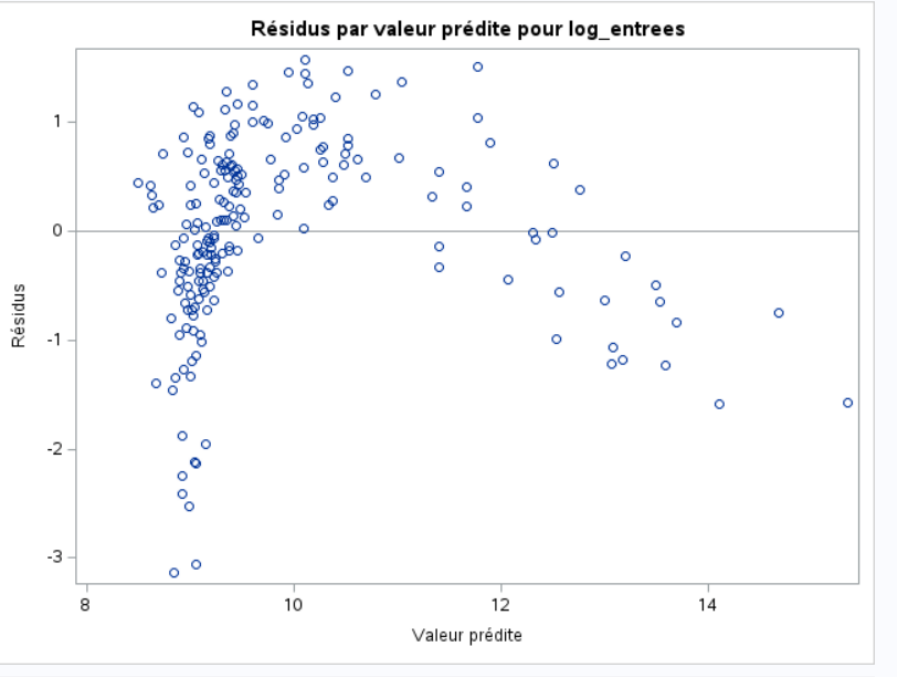

Le graphique des résidus présente une structure non aléatoire en forme de parabole. Cette tendance suggère que la relation entre les variables n'est pas purement linéaire.

AMELIORATION DU MODELE ET TRAITEMENT DES POINTS INFLUENTS

A la suite de l'analyse des premiers résultats, une étape de nettoyage des données a été effectuée pour optimiser la précision des estimations.

Identification et suppression : Nous avons identifié les points influents en utilisant deux critères statistiques :

- Les résidus studentises (valeur absolue supérieure a 2) : pour detecter les observations dont les entrees s'ecartent anormalement des predictions du modele.

Points influents identifiés

Obs.	nom	entrees_2022	fauteuils	seances	res_stud	levier	cook
10	ARTPLEXE	104378	824	12787	-1.14982	0.05602	0.02611
15	PATHE	1124133	3507	29080	-0.92470	0.14909	0.04998
27	PLEIN AIR LE CHATEAU	1136	200	9	-2.15878	0.00827	0.01272
47	SALLE COMMUNALE	635	150	10	-2.92821	0.00731	0.02025
65	REX	26198	807	2616	1.32110	0.03404	0.02043
78	PRADO	231836	1433	18082	-1.44061	0.06090	0.04462
82	CINEUM CANNES	329960	2344	16654	0.96384	0.08623	0.02923
104	CGR VITROLLES	274735	2446	23424	-1.86833	0.06252	0.07662
115	SUPERDEVOLUY REX	1018	145	205	-2.45201	0.00690	0.01357
116	LA TANIERE	1334	89	258	-2.24156	0.00707	0.01169
117	CINEMEDITERRANEE	671	200	21	-2.78870	0.00823	0.02078
127	LES TROIS PALMES	592641	2436	16674	1.81989	0.10380	0.12638
131	PATHE	967608	3271	30098	-1.89917	0.11603	0.15574
145	SALLE POLYVALENTE	791	200	17	-2.59015	0.00824	0.01806
155	MEGARAMA	160108	1515	17199	-1.37333	0.04093	0.02671
156	SALLE ANDRE BAGUR	1019	120	77	-2.43710	0.00699	0.01359
158	CAP CINEMA MANOSQUE	140731	1214	15784	-1.41879	0.05165	0.03636
161	CGR LE SPOT - LA CIOTAT	165255	1305	16140	-1.23189	0.04653	0.02462
165	MUCEM	299	263	13	-3.67926	0.01049	0.04496
193	CINEMA LE MIDIC	405	99	34	-3.57144	0.00705	0.02849

nous procédons a une nouvelle série de tests de diagnostic afin de valider la robustesse du modèle.

Equation obtenue : $\mathbf{log}(\boldsymbol{entree}_{\mathbf{2022}}) = \mathbf{9,31823} - \mathbf{0,00171} \times \boldsymbol{fauteuils} + \mathbf{0,00040432} \times \boldsymbol{séances}$

Coefficient de détermination (R2) : R-carre = 0,7575 (soit 75,75 % de la variance expliquee)

Le **R2** est passe de 0,69 à 0,75.

- **La liaison globale entre ces deux variables est-elle significative ?**

$$H_0 : CMexp = CMres$$
$$H_1 : CMexp \neq CMres$$

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	2	242.28438	121.14219	274.92	<.0001
Erreur	176	77.55272	0.44064		
Total sommes corrigées	178	319.83710			

La probabilité critique est inférieure à 0.05 donc on rejette H0

Test marginaux de Student :

H0 : βj = 0 H1 : βj ≠0 j = 1…2

Paramètres estimés								
Variable	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > |t|	Inflation de variance	Intervalle de confiance à95%	
Intercept	1	9.31823	0.06934	134.38	<.0001	0	9.18137	9.45508
fauteuils	1	-0.00171	0.00031466	-5.45	<.0001	8.32287	-0.00234	-0.00109
seances	1	0.00040432	0.00003106	13.02	<.0001	8.32287	0.00034302	0.00046563

Les valeurs des VIFS indiquent une multi-colinéarité entre les variables fauteuils et séances, cela nous pousse à réaliser un nouveau modelé à la suite des hypothèses pour régler ce problème.

- **Les résidus ont-ils une espérance nulle ?**

$$H_0 : E(\varepsilon x) = 0$$
$$H_1 : E(\varepsilon x) \neq 0$$

Tests de tendance centrale : Mu0=0				
Test	Statistique		p-value	
t de Student	t	0	Pr > |t|	1.0000
Signe	M	-1.5	Pr >= |M|	0.8812
Rang signé	S	98	Pr >= |S|	0.8882

La probabilité critique est supérieure au seuil 0.05 donc on accepte H0, les résidus ont bien une espérance nulle

- **Les résidus suivent-ils une loi normale ?**

Test de Normalité :

$$H_0 : \textit{Les résidus suivent une loi Normale}$$
$$H_1 : \textit{Les résidus ne suivent pas une loi Normale}$$

Tests de normalité				
Test	Statistique		p-value	
Shapiro-Wilk	W	0.986121	Pr < W	0.0743
Kolmogorov-Smirnov	D	0.061681	Pr > D	0.0937
Cramer-von Mises	W-Sq	0.081052	Pr > W-Sq	0.2072
Anderson-Darling	A-Sq	0.500184	Pr > A-Sq	0.2145

La probabilité est supérieure à 0.05 donc on accepte H0.

- **Sont-ils indépendants ?**

Test de non-corrélation :

$$H_0 : \textit{Les résidus ne sont pas corrélés}$$
$$H_1 : \textit{Les résidus sont corrélés}$$

Durbin-Watson D	2.154
Pr < DW	0.8497
Pr > DW	0.1503
Nombre d'observations	179
Autocorrélation de 1er ordre	-0.090

La statistique DW doit être comprise entre 1,5 et 2,5 donc on peut accepter H0.

- **Les résidus ont-ils une variance commune ?**
-

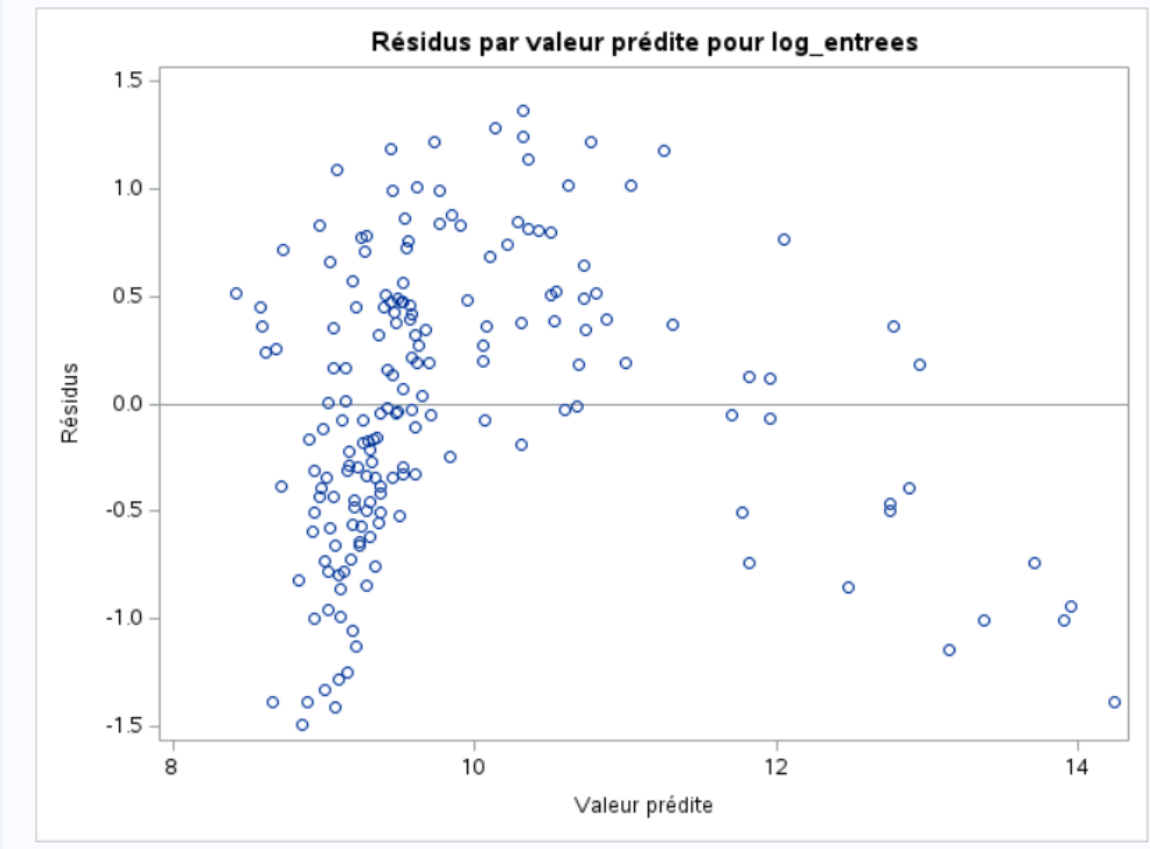

L'analyse du graphique des résidus après suppression des points influents montre une nette amélioration : l'amplitude des erreurs est réduite de moitié et le nuage de points est plus homogène. Cependant, une légère forme persiste

Nous allons remplacer la transformation logarithmique de la variable dépendante (log_entrees) par une transformation en racine carrée.

Changement de variable : $entree_{2022}: \rightarrow \sqrt{entree_{2022}}$

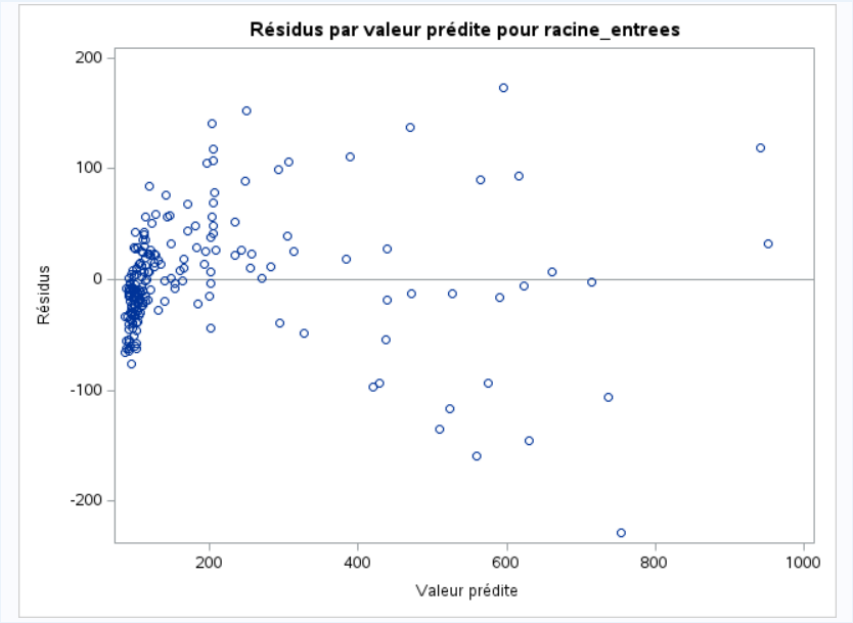

L'examen du graphique des résidus pour la variable **racine_entrees** montre une dégradation de la qualité du modèle par rapport à la transformation logarithmique :

Amplification de l'effet "entonnoir" **:** On observe une forme triangulaire très marquée. La dispersion des résidus augmente considérablement à mesure que les valeurs prédites s'élèvent. Cela confirme une forte **hétéroscédasticité**.

Changement de variable dans le modèle nous remplaçons séance par semaines_activite pour des raisons de multi-colinéarité entre fauteuils et séances.

- Déterminer l'équation estimée de la droite des moindres carrés. Déterminer le coefficient de détermination.

Paramètres estimés								
Variable	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > |t|	Inflation de variance	Intervalle de confiance à95%	
Intercept	1	5.88218	0.21110	27.86	<.0001	0	5.46587	6.29849
fauteuils	1	0.00158	0.00009047	17.51	<.0001	1.06774	0.00141	0.00176
semaines_activite	1	0.07085	0.00462	15.34	<.0001	1.06774	0.06174	0.07996

R carré 0.7867

L'équation estimé de l'hyperplan de la droite s'ajuste bien aux données, la variation de la racine des entrée2022 est expliqué a 79% par l'équation estimé de l'hyperplan entre la racine des entrée 2021, les fauteuils et les semaines d'activités

- **La liaison globale entre ces deux variables est-elle significative ?**

- **La liaison globale entre ces deux variables est-elle significative ?**

$$H_0 : CMexp = CMres$$
$$H_1 : CMexp \neq CMres$$

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	2	392.25965	196.12982	361.54	<.0001
Erreur	196	106.32836	0.54249		
Total sommes corrigées	198	498.58800			

La probabilité critique est inférieure à 0.05 donc on rejette H0

Test marginaux de Student :

H0 : βj = 0 H1 : βj ≠0 j = 1…2

Paramètres estimés								
Variable	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > |t|	Inflation de variance	Intervalle de confiance à95%	
Intercept	1	5.88218	0.21110	27.86	<.0001	0	5.46587	6.29849
fauteuils	1	0.00158	0.00009047	17.51	<.0001	1.06774	0.00141	0.00176
semaines_d_activite	1	0.07085	0.00462	15.34	<.0001	1.06774	0.06174	0.07996

Les valeurs des VIFS indiquent qu'il n'ya plus de problème de multi-colinéarité entre les variables fauteuils et séances,

- **Les résidus ont-ils une espérance nulle ?**

$$H_0 : E(\varepsilon x) = 0$$
$$H_1 : E(\varepsilon x) \neq 0$$

Tests de tendance centrale : Mu0=0				
Test	Statistique		p-value	
t de Student	t	0	Pr > |t|	1.0000
Signe	M	2.5	Pr >= |M|	0.7768
Rang signé	S	234	Pr >= |S|	0.7744

La probabilité critique est supérieure au seuil 0.05 donc on accepte H0, les résidus ont bien une espérance nulle

- **Les résidus suivent-ils une loi normale ?**

Test de Normalité :

$$H_0 : \textit{Les résidus suivent une loi Normale}$$
$$H_1 : \textit{Les résidus ne suivent pas une loi Normale}$$

Tests de tendance centrale : Mu0=0				
Test	Statistique		p-value	
t de Student	t	0	Pr > |t|	1.0000
Signe	M	2.5	Pr >= |M|	0.7768
Rang signé	S	234	Pr >= |S|	0.7744

La probabilité est supérieure à 0.05 donc on accepte H0.

- **Sont-ils indépendants ?**

Test de non-corrélation :

$$H_0 : \textit{Les résidus ne sont pas corrélés}$$
$$H_1 : \textit{Les résidus sont corrélés}$$

Durbin-Watson D	1.836
Pr < DW	0.1241
Pr > DW	0.8759
Nombre d'observations	199
Autocorrélation de 1er ordre	0.081

La statistique DW doit être comprise entre 1,5 et 2,5 donc on peut accepter H0.

- **Les résidus ont-ils une variance commune ?**
-

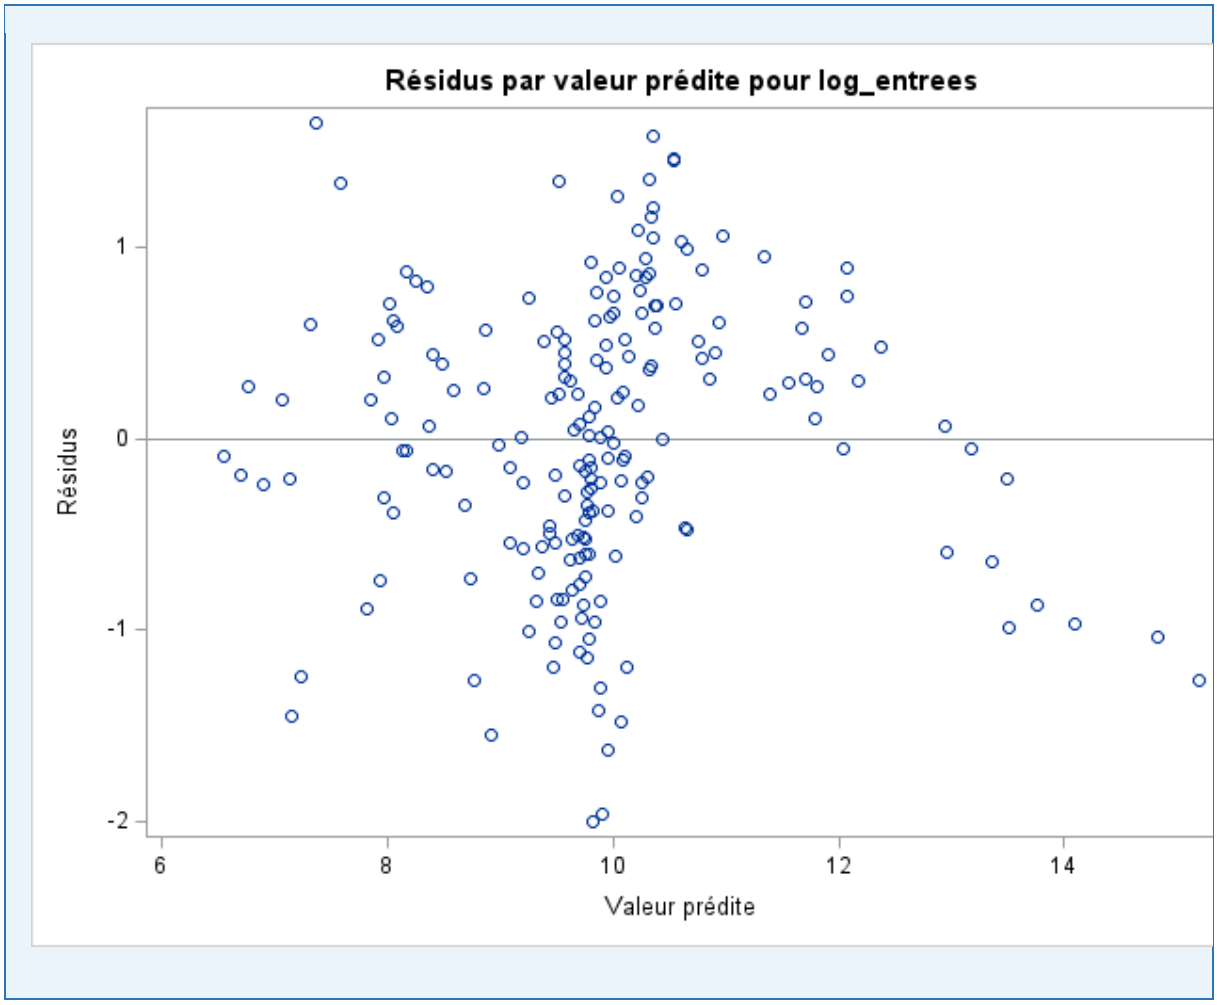

Il n'y a pas de forme particulière

Apres avoir teste plusieurs transformations, nous avons arrête notre choix sur le modèle logarithmique et les fauteuils et semaines_activite en variables quantitative indépendantes y.

Justification du rejet des autres modèles :

1. Modèle Linéaire simple : Présentait une forte hétéroscédasticité et une forme marquée.
2. Modèle Racine Carrée : A aggrave la dispersion des résidus (effet entonnoir accentue), rendant les estimations instables.
3. Modèle log: problème de multi colinéarité avec les VIF

7. Régression linéaire multiple (3+ Variables quantitatives indépendantes)

- **Déterminer l'équation estimée de l'hyperplan des moindres carrés. Déterminer le coefficient de détermination.**

Paramètres estimés					
Variable	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > |t|
Intercept	1	6.85321	0.23518	29.14	<.0001
fauteuils	1	0.00010598	0.00029824	0.36	0.7227
seances	1	0.00005470	0.00004577	1.20	0.2336
ecrans	1	-0.02937	0.09163	-0.32	0.7489
pop_commune	1	3.206098E-7	1.991702E-7	1.61	0.1092
pop_uu	1	-1.02461E-8	9.336093E-9	-1.10	0.2739
semaines_activite	1	0.04401	0.00513	8.58	<.0001
nb_films_prog	1	0.00646	0.00240	2.70	0.0077
nb_films_inedits	1	-0.00530	0.00216	-2.45	0.0152
nb_films_sem1	1	0.00901	0.00123	7.33	<.0001
nb_films_ae	1	-0.00219	0.00158	-1.38	0.1678
entrees_2021	1	0.00000266	0.00000109	2.44	0.0155

Equation du modèle

log(entrees) = 6,85321 + 0,00010598 * fauteuils + 0,00005470 * seances - 0,02937 * ecrans + 0,0000003206 * pop_commune - 0,0000000102 * pop_uu + 0,04401 * semaines_activite + 0,00646 * nb_films_prog - 0,00530 * nb_films_inedits + 0,00901 * nb_films_sem1 - 0,00219 * nb_films_ae + 0,00000266 * entrees_2021

R carré	0.8824

- **La liaison globale entre toutes ces variables est-elle significative ?**

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	11	399.64469	36.33134	124.16	<.0001
Erreur	182	53.25787	0.29263		
Total sommes corrigées	193	452.90257			

La valeur critique est supérieure à 0.05 donc on rejette
La liaison entre les entrées en 2022 et les 11 autres variables est significative

- **Quelles sont les variables qui ont une influence significative sur les entrées en 2022 ?**

Paramètres estimés					
Variable	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > |t|
Intercept	1	6.85321	0.23518	29.14	<.0001
fauteuils	1	0.00010598	0.00029824	0.36	0.7227
seances	1	0.00005470	0.00004577	1.20	0.2336
ecrans	1	-0.02937	0.09163	-0.32	0.7489
pop_commune	1	3.206098E-7	1.991702E-7	1.61	0.1092
pop_uu	1	-1.02461E-8	9.336093E-9	-1.10	0.2739
semaines_activite	1	0.04401	0.00513	8.58	<.0001
nb_films_prog	1	0.00646	0.00240	2.70	0.0077
nb_films_inedits	1	-0.00530	0.00216	-2.45	0.0152
nb_films_sem1	1	0.00901	0.00123	7.33	<.0001
nb_films_ae	1	-0.00219	0.00158	-1.38	0.1678
entrees_2021	1	0.00000266	0.00000109	2.44	0.0155

Les principaux **variables qui ont une influence** des entrées en 2022 sont l'intensité de l'exploitation (semaines d'activité) et la richesse de la programmation (nombre de films en semaine 1 et total programmé). Les capacités physiques du cinéma (fauteuils, écrans) ne sont pas significatives dans ce modèle.

- **Les résidus ont-ils une espérance nulle ?**

$$\boldsymbol{H_0} : \boldsymbol{E}(\varepsilon x) = \mathbf{0}$$
$$\boldsymbol{H_1} : \boldsymbol{E}(\varepsilon x) \neq \mathbf{0}$$

Tests de tendance centrale : Mu0=0				
Test	Statistique		p-value	
t de Student	t	0	Pr > |t|	1.0000
Signe	M	8	Pr >= |M|	0.2815
Rang signé	S	286.5	Pr >= |S|	0.7155

La probabilité critique est égale à 1 donc supérieure a 0.05 on accepte H0.
Les v.a .ßx ont une espérance nulle

- **Les résidus suivent-ils une loi normale ?**

Test de Normalité :

$$H_0 : \textit{Les résidus suivent une loi Normale}$$
$$H_1 : \textit{Les résidus ne suivent pas une loi Normale}$$

Tests de normalité				
Test	Statistique		p-value	
Shapiro-Wilk	W	0.989907	Pr < W	0.1896
Kolmogorov-Smirnov	D	0.044967	Pr > D	>0.1500
Cramer-von Mises	W-Sq	0.054551	Pr > W-Sq	>0.2500
Anderson-Darling	A-Sq	0.391037	Pr > A-Sq	>0.2500

La probabilité critique est supérieure à 0.05, on accepte H0

- **Sont-ils indépendants ?**

$$H_0 : \textit{Les résidus ne sont pas corrélés}$$
$$H_1 : \textit{Les résidus sont corrélés}$$

Durbin-Watson D	1.892
Pr < DW	0.2262
Pr > DW	0.7738
Nombre d'observations	194
Autocorrélation de 1er ordre	0.053

La statistique de Durbin Watson est égale à doit être comprise entre 1.5 et 2.5 donc on peut accepter H0.

- **Les résidus ont-ils une variance commune ?**

$$H_0 : Var(\beta) = \sigma^2$$
$$H_1 : Var(\beta) \neq \sigma^2$$

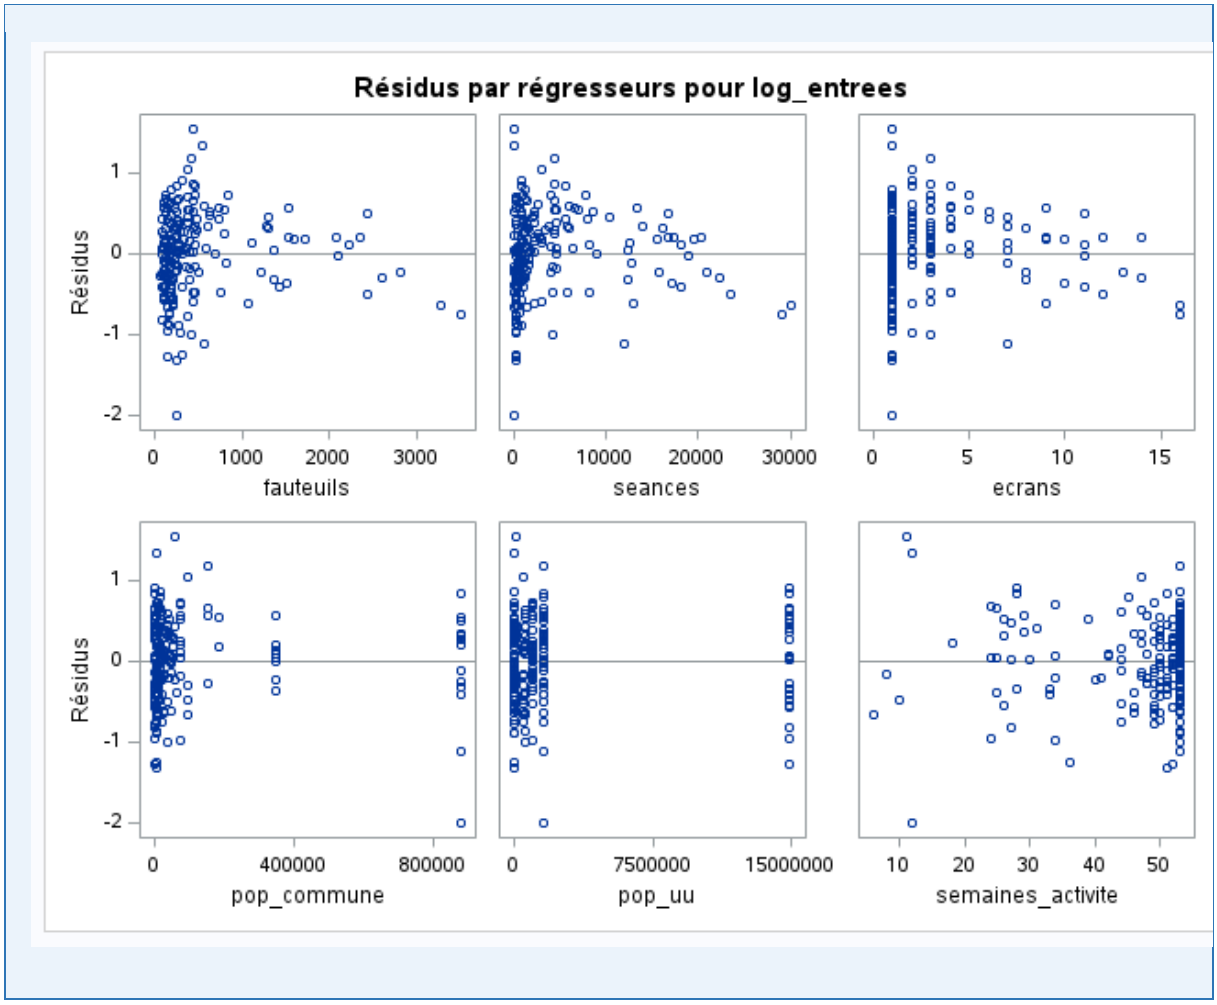

L'examen des résidus en fonction de chaque variable explicative révèle des défauts de spécification du modèle : **Hétéroscédasticité marquée**

H0 est rejetée.
Détection d'observations atypiques

- **Déterminer les points ayant une forte influence sur le calcul des paramètres du modèle.**
- Avec k = 11 (nombre de variables explicatives)
- Et n = 199 (nombre d'observations)
- **Seuil = 0,1206**

Toutes les observations dépassant ce seuil de **0,1206** ont été listées.

Liste des points influents et leviers hors seuils

Obs.	nom	levier
6	CHATEAU DE LA BUZINE	0.12405
10	ARTPLEXE	0.13905
15	PATHE	0.39749
55	UTOPIA MANUTENTION 1	0.17812
72	RIALTO	0.12804
78	PRADO	0.13533
82	CINEUM CANNES	0.26007
95	PATHE CAP SUD	0.12953
104	CGR VITROLLES	0.19238
110	LES VARIETES	0.19693
118	ARMAND LUNEL	0.36570
120	PATHE LINGOSTIERE	0.13609
127	LES TROIS PALMES	0.21721
131	PATHE	0.25270
154	LE FLORIAN	0.17486
155	MEGARAMA	0.16291
161	CGR LE SPOT - LA CIOTAT	0.16602
165	MUCEM	0.15493
183	CINEMA LA JOLIETTE	0.24781
190	PATHE NICE GARE DU SUD	0.13431
195	CINEPLANET	0.14946

- Déterminer les points mal reconstitués par le modèle

18 2.3654
110 2.331
126 -2.485
164 2.470
165 4.045
180 2.599

Ces observations sont mal reconstituées par le modèle.

- Est-ce qu'il y a des variables qui sont corrélées 2 par 2 ?

Corrélation

Variable	fauteuils	seances	ecrans	pop_commune	pop_uu	semaines_activite	nb_films_prog	nb_films_inedits	nb_films_sem1	nb_films_ae	entrees_2021	log_entrees
fauteuils	1.0000	0.9502	0.9593	0.2614	-0.1514	0.2470	0.2947	0.3077	0.7214	-0.0694	0.8973	0.7431
seances	0.9502	1.0000	0.9877	0.3143	-0.1833	0.3543	0.4222	0.4171	0.8222	0.0599	0.8611	0.8313
ecrans	0.9593	0.9877	1.0000	0.3268	-0.1603	0.3194	0.3953	0.3939	0.8153	0.0307	0.8590	0.8123
pop_commune	0.2614	0.3143	0.3268	1.0000	-0.0983	0.0899	0.1288	0.0261	0.2673	0.1249	0.2311	0.3073
pop_uu	-0.1514	-0.1833	-0.1603	-0.0983	1.0000	-0.4344	-0.3263	-0.3202	-0.2195	-0.2791	-0.1295	-0.3334
semaines_activite	0.2470	0.3543	0.3194	0.0899	-0.4344	1.0000	0.6169	0.6305	0.4075	0.4434	0.2542	0.6349
nb_films_prog	0.2947	0.4222	0.3953	0.1288	-0.3263	0.6169	1.0000	0.9510	0.5617	0.8512	0.2932	0.6261
nb_films_inedits	0.3077	0.4171	0.3939	0.0261	-0.3202	0.6305	0.9510	1.0000	0.5414	0.7353	0.2972	0.5976
nb_films_sem1	0.7214	0.8222	0.8153	0.2673	-0.2195	0.4075	0.5617	0.5414	1.0000	0.3020	0.6290	0.8451
nb_films_ae	-0.0694	0.0599	0.0307	0.1249	-0.2791	0.4434	0.8512	0.7353	0.3020	1.0000	-0.0064	0.3325
entrees_2021	0.8973	0.8611	0.8590	0.2311	-0.1295	0.2542	0.2932	0.2972	0.6290	-0.0064	1.0000	0.7002
log_entrees	0.7431	0.8313	0.8123	0.3073	-0.3334	0.6349	0.6261	0.5976	0.8451	0.3325	0.7002	1.0000

- fauteuils et écrans : Corrélation = 0,9593 | R2 = 0,920

- séances et écrans : Corrélation = 0,9877 | R2 = 0,975
- fauteuils et séances : Corrélation = 0,9502 | R2 = 0,903
- nb_films_prog et nb_films_inedits : Corrélation = 0,9510 | R2 = 0,904
- nb_films_prog et nb_films_ae : Corrélation = 0,8512 | R2 = 0,724
- entrees_2021 et fauteuils : Corrélation = 0,8973 | R2 = 0,805

Toutes ces paires de variables sont corrélées.

- Déterminer un ou plusieurs groupes de variables corrélées entre elles ?

Paramètres estimés								
Variable	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > |t|	Inflation de variance	Intervalle de confiance à95%	
Intercept	1	6.85321	0.23518	29.14	<.0001	0	6.38918	7.31724
fauteuils	1	0.00010598	0.00029824	0.36	0.7227	21.37374	-0.00048248	0.00069444
seances	1	0.00005470	0.00004577	1.20	0.2336	48.44453	-0.00003560	0.00014500
ecrans	1	-0.02937	0.09163	-0.32	0.7489	57.63417	-0.21016	0.15142
pop_commune	1	3.206098E-7	1.991702E-7	1.61	0.1092	1.36555	-7.23698E-8	7.135895E-7
pop_uu	1	-1.02461E-8	9.336093E-9	-1.10	0.2739	1.29222	-2.8667E-8	8.174778E-9
semaines_activite	1	0.04401	0.00513	8.58	<.0001	1.98521	0.03388	0.05414
nb_films_prog	1	0.00646	0.00240	2.70	0.0077	36.21199	0.00173	0.01119
nb_films_inedits	1	-0.00530	0.00216	-2.45	0.0152	16.26619	-0.00956	-0.00103
nb_films_sem1	1	0.00901	0.00123	7.33	<.0001	4.42177	0.00658	0.01143
nb_films_ae	1	-0.00219	0.00158	-1.38	0.1678	9.75343	-0.00531	0.00092950
entrees_2021	1	0.00000266	0.00000109	2.44	0.0155	5.62323	5.117011E-7	0.00000481

L'analyse des facteurs d'inflation de la variance (VIF) confirme une forte colinéarité. Un premier groupe concerne les infrastructures avec des VIF de 57,63 pour les écrans, 48,44 pour les séances et 21,37 pour les fauteuils. Ces chiffres très élevés expliquent le manque de significativité individuelle de ces variables qui sont redondantes. Un second groupe lie à la programmation apparait avec le nombre de films programmes (VIF de 36,21) et le nombre de films inédits (16,26), montrant que ces deux indicateurs apportent la même information au modèle.

A l'inverse, les variables d'environnement sont statistiquement saines avec des VIF proches de 1, comme la population de l'unité urbaine (1,29), la population de la commune (1,36) et les semaines d'activité (1,98). Cette absence de corrélation garantit une estimation fiable de leur impact sur les entrées. En conclusion, la multi colinéarité des variables de capacite et de programmation rend le modèle complet instable, justifiant l'utilisation d'une méthode de sélection de variables pour ne garder que les prédicteurs les plus pertinents.

Choix du modèle – méthodes de sélection

Présentation de la méthode

Afin de résoudre les problèmes de multicolinéarité identifiés dans le modèle complet et de ne retenir que les variables les plus pertinentes, une méthode de sélection automatique de variables a été appliquée : la **sélection stepwise**

Cette procédure introduit les variables une par une selon leur contribution au modèle (valeur de F la plus élevée), tout en vérifiant à chaque étape que les variables déjà présentes restent significatives.

Déroulement de la sélection :

La procédure s'est déroulée en 4 étapes sur 199 observations.

Étape 1 — La variable nombre_de_films_en_semaine_1 est introduite en premier avec le R^2 partiel le plus élevé parmi toutes les candidates : **R^2 = 0,7001** (F = 459,94 ; p < 0,0001). Le nombre de films programmés en première semaine explique à lui seul 70 % de la variabilité du logarithme des entrées.

Étape 2 — La variable semaines_d_activite est introduite, portant le R^2 du modèle à **0,8266** (F = 142,95 ; p < 0,0001), soit un gain de 12,65 points de R^2 partiel. Les semaines d'activité du cinéma constituent donc la deuxième variable explicative la plus importante.

Étape 3 — La variable seances est introduite, portant le R^2 à **0,8733** (F = 71,86 ; p < 0,0001), avec un gain de 4,67 points. Le nombre de séances apporte une information complémentaire significative, indépendamment des deux premières variables.

Étape 4 — La variable population_de_la_commune entre dans le modèle, portant le R^2 final à **0,8761** (F = 4,33 ; p = 0,0387), avec un gain marginal de 0,28 point. Bien que ce gain soit faible, la variable reste significative au seuil de 5 %.

À l'issue de l'étape 4. Le processus s'arrête.

Modèle retenu :

Le modèle sélectionné par la procédure stepwise est :

$$\log(entrees_{2022}) = 6{,}6097 + 0{,}000099 \times séances + 0{,}0000003897 \times pop_{commune} + 0{,}05222 \times semaines_{activités} + 0{,}00859 \times nb_films_sem1$$

R^2 = 0,8761

L'équation estimée de l'hyperplan s'ajuste très bien aux données, la variation du logarithme des entrées 2022 est expliquée à 87,61 % par l'équation estimée de l'hyperplan entre le nombre de séances, la population de la commune, les semaines d'activité et le nombre de films en semaine 1.

- **La liaison globale entre toutes ces variables est-elle significative ?**

Test global de Fisher :

$$H_0 : \forall j \in \{1,2,3,4\}, \beta j = 0$$

$$H_1 : \exists j \in \{1,2,3,4\}, \beta j \neq 0$$

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	4	436.79125	109.19781	342.81	<.0001
Erreur	194	61.79675	0.31854		
Total sommes corrigées	198	498.58800			

La probabilité critique est inférieure à 0,05 (p < 0,0001) donc on rejette H0.

La liaison globale entre le logarithme des entrées 2022 et les quatre variables explicatives (séances, population de la commune, semaines d'activité et nombre de films en semaine 1) est significative.

- Quelles sont les variables qui ont une influence significative sur les entrées_2022 ?

Tests marginaux de Student :

H0 : $\beta j = 0$

H1 : $\beta j \neq 0$ $j = 1, ..., p$

Paramètres estimés								
Variable	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > |t|	Inflation de variance	Intervalle de confiance à95%	
Intercept	1	6.60968	0.16615	39.78	<.0001	0	6.28199	6.93737
seances	1	0.00009870	0.00001224	8.06	<.0001	3.21604	0.00007456	0.00012285
population_de_la_commune	1	3.897033E-7	1.872507E-7	2.08	0.0387	1.11353	2.039481E-8	7.590117E-7
semaines_d_activite	1	0.05222	0.00377	13.84	<.0001	1.21342	0.04477	0.05966
nombre_de_films_en_semaine_1	1	0.00859	0.00110	7.83	<.0001	3.29398	0.00643	0.01076

Toutes les variables retenues par le modèle sont individuellement significatives au seuil de 5 % :

- `seances` : $t = 8{,}06$; $p < 0{,}0001$
- `population_de_la_commune` : $t = 2{,}08$; $p = 0{,}0387$
- `semaines_d_activite` : $t = 13{,}84$; $p < 0{,}0001$
- `nb_films_en_semaine_1` : $t = 7{,}83$; $p < 0{,}0001$

On rejette H0 pour chacune de ces variables, elles ont toutes une influence significative sur le logarithme des entrées 2022.

Par ailleurs, les valeurs des VIF sont toutes proches de 1 (maximum 3,29 pour nb_films_en_semaine_1), ce qui indique l'absence de multi colinéarité entre les variables du modèle retenu. La sélection stepwise a donc permis de résoudre efficacement les problèmes de multicolinéarité identifiés dans le modèle complet.

- **Les résidus ont-ils une espérance nulle ?**

H0 : $E(\varepsilon x) = 0$

H1 : $E(\varepsilon x) \neq 0$

Tests de tendance centrale : Mu0=0				
Test	Statistique		p-value	
t de Student	t	0	Pr > |t|	1.0000
Signe	M	4.5	Pr >= |M|	0.5708
Rang signé	S	212	Pr >= |S|	0.7951

La probabilité critique du test de Student est égale à 1,0000, soit largement supérieure au seuil de 0,05, donc on accepte H0.

Les v.a .ßx ont une espérance nulle

- **Les résidus suivent-ils une loi normale ?**

$$\boldsymbol{H_0 : \ Les\ résidus\ suivent\ une\ loi\ Normale}$$
$$\boldsymbol{H_1 : \ Les\ résidus\ ne\ suivent\ pas\ une\ loi\ Normale}$$

N = 199 (test de Kolmogorov-Smirnov)

Tests de normalité				
Test	Statistique		p-value	
Shapiro-Wilk	W	0.991357	Pr < W	0.2828
Kolmogorov-Smirnov	D	0.037206	Pr > D	>0.1500
Cramer-von Mises	W-Sq	0.048607	Pr > W-Sq	>0.2500
Anderson-Darling	A-Sq	0.367309	Pr > A-Sq	>0.2500

La probabilité critique est supérieure à 0.05, on accepte H0

- **Sont-ils indépendants ?**

$$H_0 : \text{ les v. a E(ß) sont corrélées}$$
$$H_1 : \text{ les v. a E(ß)ne sont pas corrélées}$$

Durbin-Watson D	1.902
Pr < DW	0.2421
Pr > DW	0.7579
Nombre d'observations	199
Autocorrélation de 1er ordre	0.048

La statistique de Durbin watson est entre 1.5 et 2.5.

- **Les résidus ont-ils une variance commune ?**

$$\boldsymbol{H_0} : \boldsymbol{Var}(ß) \ = \ \sigma^2$$

$$\boldsymbol{H_1} : \boldsymbol{Var}(ß) \ \neq \ \sigma^2$$

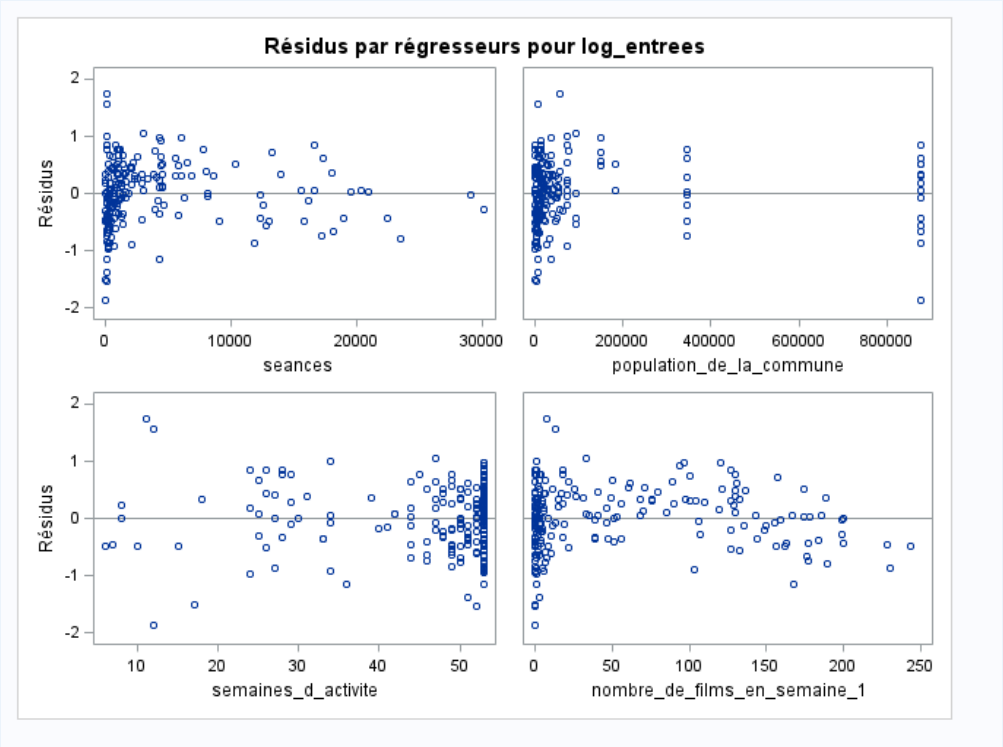

Pas de forme d'entonnoir donc on accepte H0

8. Modèle d'analyse de la variance avec une variable

La variable sit_geo comporte 3 modalités correspondant à la taille des unités urbaines : les grandes agglomérations de 100 000 habitants ou plus (modalité 04), les unités urbaines moyennes de 20 000 à 100 000 habitants (modalité 05), et les autres communes et petites unités urbaines (modalité 06). L'objectif est de déterminer si la situation géographique d'un cinéma a une influence significative sur son nombre d'entrées en 2022.

- **La situation géographique a-t-elle une influence significative sur les entrées en 2022 ?**

  Test Global de Fisher :

$$H_0 : CMexp = CMres$$
$$H_1 : CMexp \neq CMres$$

Source	DDL	Somme des carrés	Carré moyen	Valeur F	Pr > F
Modèle	2	158633793584	79316896792	4.07	0.0185
Erreur	196	3.8184901E12	19482092265		
Total sommes corrigées	198	3.9771239E12			

La probabilité critique est inférieure à 0.05 donc on rejette Ho.

La situation géographique a bien une influence significative sur les entrées en 2022

- **Quelle part de variation des entrées 2022 est expliquée par le modèle impliquant le facteur situation géographique ?**

R-carré	Coef de var	Racine MSE	entrees_2022 Moyenne
0.039887	208.1280	139578.3	67063.66

Seulement 3,99 % de la variation des entrées 2022 est expliquée par la situation géographique.

Analyse individuelle des modalités du facteur engrais

- **Déterminer les moyennes des 3 modalités du facteur engrais.**

situation_geographique	N	Moyenne	95% Confiance Limites	
04-Unites urbaines de 100 000 hbts ou plus	133	84968	61099	108837
05-Unites urbaines de 20 000 à 100 000 hbts	14	72128	-1441	145696
06-autres communes et unites urbaines	52	19906	-18267	58079

- **L'homogénéité des variances est-elle vérifiée ?**

Ho : Les v.a ßx ont une variance commune
H1 : Les v.a ßx n'ont pas une variance commune

Test de Levene pour l'homogénéité de la variance entrees_2022 ANOVA des écarts au carré des moyennes de groupe					
Source	DDL	Somme des carrés	Carré moyen	Valeur F	Pr > F
situation_geographiq	2	3.15E22	1.575E22	1.66	0.1935
Erreur	196	1.864E24	9.511E21		

La probabilité critique est égale à 0.1935 supérieure à 0.05 donc on accepte Ho.

Les v.a ßx ont une variance commune.

- **Quelles sont les situations géographiques qui obtiennent des entrées moyennes significativement différentes (prises 2 à 2) ?**

Comparaisons significatives au niveau 0.05 indiquées par ***.				
situation_geographique Comparaison	Différence/Entre/Moyennes	95% - Intervalle de confiance		
04-Unites urbaines de 100 000 hbts ou plus - 05-Unites urbaines de 20 000 à 100 000 hbts	12840	-64503	90184	
04-Unites urbaines de 100 000 hbts ou plus - 06-autres communes et unites urbaines	65062	20041	110083	***
05-Unites urbaines de 20 000 à 100 000 hbts - 04-Unites urbaines de 100 000 hbts ou plus	-12840	-90184	64503	
05-Unites urbaines de 20 000 à 100 000 hbts - 06-autres communes et unites urbaines	52222	-30661	135104	
06-autres communes et unites urbaines - 04-Unites urbaines de 100 000 hbts ou plus	-65062	-110083	-20041	***
06-autres communes et unites urbaines - 05-Unites urbaines de 20 000 à 100 000 hbts	-52222	-135104	30661	

Les situations géographiques 04 (unités urbaines de 100 000 habitants ou plus) et 06 (autres communes et unités urbaines) ont des entrées moyennes significativement différentes.

9. Tableau récapitulatif comparatif de tous les modèles testés

Modele	Variable(s) Expliquative(s)	Transformation Y	R^2	p-value F	VIF	DW	résidus	Homoscédasticité	Retenu
1 - Régression simple	fauteuils	aucune	0.8479	<0,05	-	2,083	Non	Forme en entonnoir	✗
2 - Régression simple (après suppression)	fauteuils	aucune	0,8258	<0,0001	-	2,186	Non	Forme particuliere	✗
3 - Régression simple	fauteuils	racine	0,8489	<0,0001	-	2,091	Oui	Pas de forme	✓
4 - Régression 2 variables	fauteuils + seances	log	0,6929	<,0001	-	1,978	Oui	Forme Parabole	✗
5 - Régression 2 variables (après nettoyage)	fauteuils + seances	log	0,7575	<,0001	-	2,154	Oui	Forme Parabole	✗
6 - Régression 2 variables	fauteuils + semaines_activite	log	0.7867	<,0001	-	1,836	Oui	Pas de forme	✓
7 - Régression multiple (stepwise)	seances + pop_commune + semaines_activite + nb_films_sem1	log	0,8761	<,0001	proche de 1	1,902	Oui	Pas de forme	✓

Ce tableau récapitule l'ensemble des modèles testés au cours de cette étude. Plusieurs constats ressortent de cette comparaison :

Les modèles 1 et 2 (régression simple sans transformation) ont été rejetés en raison d'une hétéroscédasticité marquée (forme en entonnoir) et d'une non-normalité des résidus, malgré un R^2 satisfaisant (0,8479 et 0,8258).

Le modèle 3 (régression simple avec transformation racine) constitue le meilleur modèle à une variable explicative avec un R^2 de 0,8489 et toutes les hypothèses validées.

Les modèles 4 et 5 (régression à deux variables log_entrees ~ fauteuils + seances) ont été rejetés en raison d'une forme parabolique des résidus traduisant une hétéroscédasticité, malgré l'amélioration apportée par le nettoyage des points influents.

Le modèle 6 (log_entrees ~ fauteuils + semaines_activite) est retenu comme meilleur modèle à deux variables avec un R^2 de 0,7867 et toutes les hypothèses validées.

Le modèle 7 (sélection stepwise) est le modèle le plus performant avec le R^2 le plus élevé (0,8761) et toutes les hypothèses validées. Il constitue le modèle final retenu pour la prévision.

10. Prévision sur 5 cinémas de régions voisines

Dernière partie du travail : sélectionner 5 cinémas dans les régions voisines de la vôtre pour lesquels on récupère les valeurs des variables que vous avez choisies dans les modèles proposés... et aussi le nombre d'entrées en 2022

ATTENTION à varier le choix de vos établissements cinématographiques, petit, multiplexe...

L'objectif est de tester vos modèles pour comparer vos estimations et leurs intervalles de prévision avec la vraie valeur du nombre d'entrées.

Indication : pour déterminer les intervalles de prévision

Ajouter à la fin du fichier excel (avant import) les lignes des cinémas choisis sans mettre le nombre d'entrées et mettre les valeurs des autres variables qu'on a récupérées même s'il y a des valeurs manquantes.

Puis relancer les procédures de régression avec l'option CLI (page 3 poly sas).

Les intervalles de prévision seront calculés dans le tableau (95 % par défaut).

L'objectif de cette dernière partie est de tester la capacité prédictive de nos modèles retenus en les appliquant à des données extérieures à notre échantillon d'apprentissage.

Sélection des cinémas

Nous avons sélectionné 5 cinémas situés dans les régions voisines de PACA, à savoir l'Occitanie et Auvergne-Rhône-Alpes. Le choix a été fait de manière à varier les profils d'établissements : multiplexe, cinéma de taille moyenne et petit cinéma de proximité. Pour chacun de ces établissements, nous avons récupéré sur le site du CNC les valeurs des variables retenues dans nos modèles (séances, population de la commune, semaines d'activité, nombre de films en semaine 1) ainsi que le nombre réel d'entrées en 2022, qui servira de valeur de référence pour évaluer la qualité des prévisions.

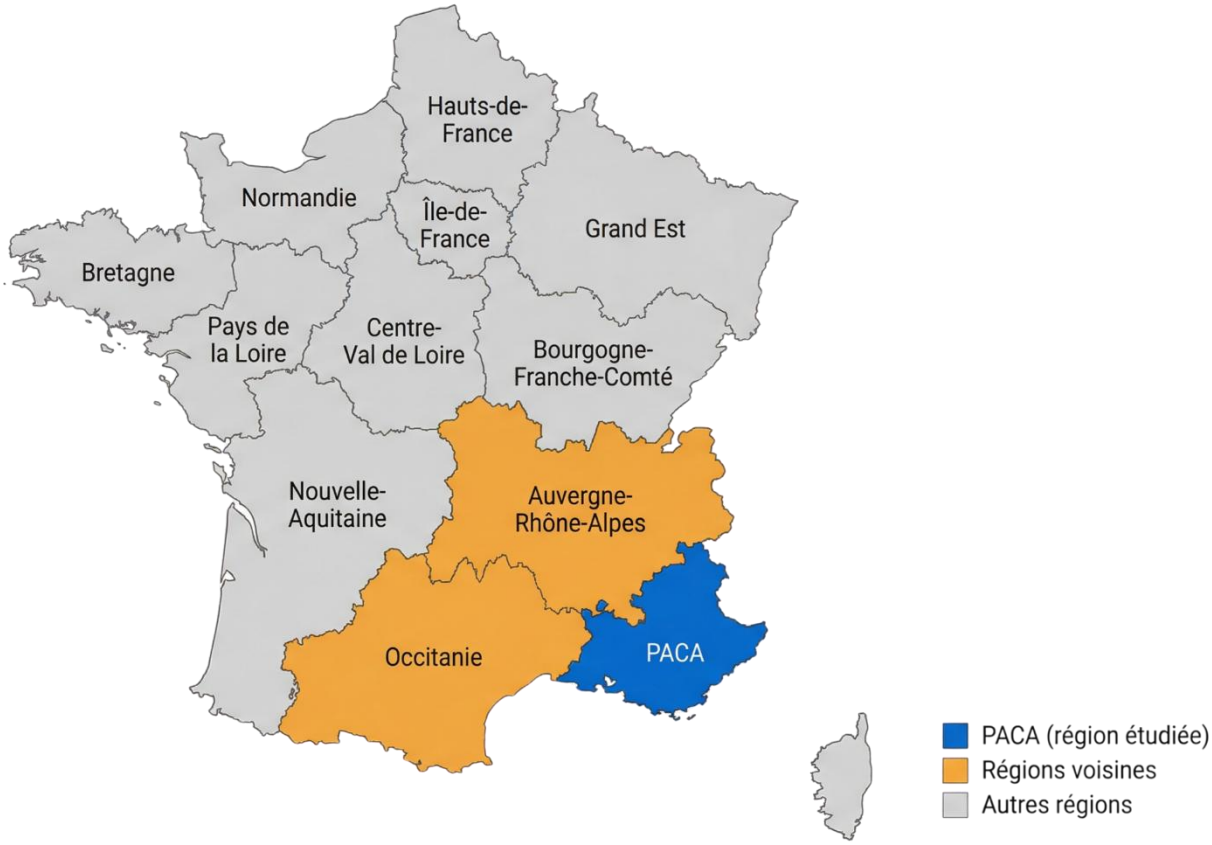

Méthodologie

Les 5 cinémas ont été ajoutés à la fin du fichier Excel sans renseigner la valeur des entrées 2022. Après réimport dans SAS, les procédures de régression ont été relancées avec l'option CLI qui permet de calculer automatiquement les **intervalles de prévision à 95 %** pour chaque nouvelle observation.

Interprétation

Pour chaque cinéma, nous comparons ensuite la vraie valeur d'entrées 2022 avec l'intervalle de prévision calculé par le modèle. Si la vraie valeur est contenue dans l'intervalle, le modèle prédit correctement. Dans le cas contraire, cela indique une limite du modèle pour ce type d'établissement.

Après ajout des 5 cinémas des régions voisines dans le fichier Excel, la table de données compte désormais 204 observations (199 cinémas PACA d'origine + 5 nouveaux cinémas), les entrées 2022 de ces 5 établissements ayant été laissées vides.

Après réimport et exécution de la procédure de régression avec l'option CLI, SAS a calculé pour chaque nouveau cinéma une valeur prédite ainsi qu'un intervalle de prévision à 95 %. Les résultats obtenus (en log) sont les suivants :

Obs.	nom	ybar	borne_inf	borne_sup
200	CINEMAUV	9.6252	9.5088	9.7417
201	UGC CINE CITE CONFLUENCE	13.5999	13.2618	13.9379
202	CGR ALBI	12.2248	12.0424	12.4072
203	LE PARC	8.5584	8.4300	8.6868
204	ESPACE LUMIERE	9.0860	8.9771	9.1949

Voici un tableau comparatif avec les entrées réelles :

Cinéma	Région	Valeur prédite (log)	IC inf (log)	IC sup (log)	Valeur prédite (entrées)	IC inf (entrées)	IC sup (entrées)	Vraie valeur	Dans l'intervalle ?
CINEMAUV	Occitanie	9,6252	9,5088	9,7417	15142	13477,8112	17012,438	4851	Non
UGC CINE CITE CONFLUENCE	AuRA	13,5999	13,2618	13,9379	806049	574813	1130194	435129	Non
CGR ALBI	Occitanie	12,2248	12,0424	12,4072	203781	169804	244556	173506	Oui
LE PARC	AuRA	8,5584	8,43	8,6868	5210	4583	5924	4330	Non
ESPACE LUMIERE	AuRA	9,086	8,9771	9,1949	8831	7920	9847	5468	Non

Commentaire :

Les résultats montrent que seulement 1 cinéma sur 5 (CGR ALBI) a sa vraie valeur d'entrées 2022 contenue dans l'intervalle de prévision à 95 %. Pour les 4 autres cinémas, la vraie valeur est systématiquement en dessous de l'intervalle prédit, ce qui indique que le modèle surestime la fréquentation.

Cette surestimation peut s'expliquer par plusieurs raisons :

-Le modèle a été construit uniquement sur les cinémas de la région PACA, qui présente une fréquentation structurellement plus élevée que la moyenne nationale (2e indice de fréquentation national avec 2,58 entrées par habitant). Il est donc logique que le modèle surestime pour des régions avec une fréquentation plus faible.

-Les cinémas choisis dans les régions voisines ont des profils très variés (petit cinéma de proximité, beaucoup ou peu de fauteuils, grand multiplexe) ce qui rend la prévision plus difficile.

Ces résultats soulignent une limite importante du modèle : sa capacité prédictive est bonne en région PACA mais reste limitée lorsqu'on l'applique à d'autres régions avec des caractéristiques différentes.

11. Conclusion et Remerciements

Conclusion

Cette SAÉ nous a permis de mettre en œuvre une démarche complète de modélisation statistique appliquée aux établissements cinématographiques de la région PACA en 2022. À travers les différentes étapes de l'analyse, nous avons pu construire, tester et comparer plusieurs modèles de régression linéaire, allant du modèle simple à une variable jusqu'au modèle multiple sélectionné par la méthode stepwise.

Le modèle final retenu log(entrées 2022) = f(séances, population de la commune, semaines d'activité, nombre de films en semaine 1) — s'est révélé le plus performant avec un R^2de 87,61 %, toutes les hypothèses sur les résidus validées et une absence de multicolinéarité entre les variables. L'analyse de variance a quant à elle mis en évidence que la situation géographique n'explique que très faiblement la fréquentation des cinémas en PACA.

La phase de prévision sur 5 cinémas des régions voisines a toutefois montré les limites du modèle, qui tend à surestimer la fréquentation réelle pour la majorité des établissements testés. Cela souligne l'importance de disposer d'un échantillon d'apprentissage suffisamment représentatif de la diversité des établissements cinématographiques.

Ce travail nous a permis de développer des compétences concrètes en modélisation statistique sous SAS, en interprétation des résultats et en rédaction d'un rapport d'analyse professionnelle.

Remerciements

Nous tenons à adresser nos sincères remerciements à Madame Herrmann pour nous avoir encadrés tout au long de cette SAÉ. Nous la remercions pour sa disponibilité, pour avoir répondu à toutes nos questions durant les séances, et pour nous avoir généreusement laissé rester dans sa salle de cours lors des séances des autres groupes, nous permettant ainsi de continuer à bénéficier de son expérience et de ses conseils précieux pour mener à bien ce travail.

Fin.